

# 浙江大学



## 《数据建模与分析》Homework

实验题目	Homework 4
学生姓名	莫非
学 号	3220103345
班 级	图灵 2201
所在学院	竺可桢学院
提交日期	2024 年 3 月 31 日

# 1 Homework 3(3.22)

## ? 6.2

写出逻辑斯谛回归模型学习的梯度下降算法。

## 6.2 Solution

直接推广到多项逻辑斯谛回归。对给定的训练数据集  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，其中  $x \in \mathbb{R}^n, y \in \{1, 2, \dots, K\}$ 。为了方便，将权重向量和输入向量加以扩充：

$$w = (w^0, w^1, \dots, w^n, b)^T, x = (1, x^1, \dots, x^n, 1)^T$$

逻辑斯谛回归模型为：

$$\begin{aligned} P(Y = k|x) &= \frac{\exp(w_k \cdot x)}{1 + \sum_{i=1}^{K-1} \exp(w_i \cdot x)}, \quad k = 1, 2, \dots, K-1 \\ P(Y = K|x) &= \frac{1}{1 + \sum_{i=1}^{K-1} \exp(w_i \cdot x)} \end{aligned} \quad (1.1)$$

对数似然函数为：

$$L(w) = \sum_{i=1}^N \sum_{j=1}^K I(y_i = j) \log P(Y = j|x_i) \quad (1.2)$$

注意到  $\sum_{j=1}^K I(y = j) = 1$ ，上式可化简为：

$$L(w) = \sum_{i=1}^N \left( \sum_{j=1}^{K-1} I(y_i = j)(w_j \cdot x_i) - \log \left( 1 + \sum_{j=1}^{K-1} \exp(w_j \cdot x_i) \right) \right) \quad (1.3)$$

---

**Algorithm 1: (多项) 逻辑斯谛回归模型学习的梯度下降法**

---

输入：目标函数  $f(w) = -L(w)$ ，梯度函数  $g(w) = \nabla L(w)$ ，计算精度  $\varepsilon$ ；

输出：最优参数值  $w^*$ ；最优模型  $P(y|x; w^*)$ 。

- 1 取初值  $w^{(0)} \in \mathbb{R}^{n+1}$ ，置  $k = 0$ 。
  - 2 计算  $f(w^{(k)})$ 。
  - 3 计算梯度  $g(w^{(k)})$ ，当  $\|g_k\| < \varepsilon$  时，停止迭代，令  $w^* = w^{(k)}$ ；  
否则，令  $p_k = -g(w^{(k)})$ ，求  $\lambda_k$ ，使
$$f(w^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(w^{(k)} + \lambda p_k)$$
  - 4 置  $w^{(k+1)} = w^{(k)} + \lambda_k p_k$ ，计算  $f(w^{(k+1)})$ 。  
当  $|f(w^{(k+1)}) - f(w^{(k)})| < \varepsilon$  或  $\|g(w^{(k+1)})\| < \varepsilon$  时，停止迭代，令  $w^* = w^{(k+1)}$ ；
  - 5 否则，置  $k = k + 1$ ，转第 3 步。
-

## 6.3

写出最大熵模型学习的 DFP 算法。（关于一般的 DFP 算法参见附录 B）

### 6.3 Solution

对最大熵模型而言,

$$P_w(y|x) = \frac{1}{Z_w(x)} \exp\left(\sum_{i=1}^n w_i f_i(x, y)\right) \quad (1.4)$$

其中规范化因子:

$$Z_w(x) = \sum_y \exp\left(\sum_{i=1}^n w_i f_i(x, y)\right) \quad (1.5)$$

求解对偶问题的外部极大化问题:

$$\max_w \Psi(w) = \max_w \sum_{x,y} \hat{P}(x, y) w_i f_i(x, y) - \sum_x \hat{P}(x) \log Z_w(x) \quad (1.6)$$

即目标函数为:

$$f(w) = -\Psi(w) = \sum_x \hat{P}(x) \log \sum_y \exp\left(\sum_{i=1}^n w_i f_i(x, y)\right) - \sum_{x,y} \hat{P}(x, y) w_i f_i(x, y) \quad (1.7)$$

#### Algorithm 2: 最大熵模型学习的 DFP 算法

输入: 特征函数  $f_1, f_2, \dots, f_n$ ; 经验分布  $\hat{P}(x, y)$ , 目标函数  $f(w)$ , 梯度函数  $g(w) = \nabla f(w)$ , 计算精度  $\varepsilon$ 。

输出: 最优参数值  $w^*$ ; 最优模型  $P(y|x; w^*)$ 。

- 1 取初值  $w^{(0)} \in \mathbb{R}^n$ , 取  $G_0$  为正定对称矩阵, 置  $k = 0$ 。
- 2 计算  $g_k = g(w^{(k)})$ , 若  $\|g_k\| < \varepsilon$ , 则停止迭代, 令  $w^* = w^{(k)}$ ; 否则, 转第 3 步。
- 3 置  $p_k = -G_k g_k$ 。
- 4 一维搜索: 求  $\lambda_k$ , 使

$$f(w^{(k)} + \lambda_k p_k) = \min_{\lambda \geq 0} f(w^{(k)} + \lambda p_k)$$

- 5 置  $w^{(k+1)} = w^{(k)} + \lambda_k p_k$ 。
- 6 计算  $g_{k+1} = g(w^{(k+1)})$ , 若  $\|g_{k+1}\| < \varepsilon$ , 则停止迭代, 令  $w^* = w^{(k+1)}$ ; 否则, 按下式求出  $G_{k+1}$ :

$$G_{k+1} = G_k + \frac{\delta_k \delta_k^T}{\delta_k^T y_k} - \frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k}$$

其中,  $y_k = g_{k+1} - g_k$ ,  $\delta_k = w^{(k+1)} - w^{(k)}$ 。

- 7 置  $k = k + 1$ , 转第 3 步。