

## 6.1 确认逻辑斯蒂分布属于指数分布族

定义6.1（逻辑斯蒂分布） 设 $X$ 是连续随机变量， $X$ 服从逻辑斯蒂分布是指 $X$ 具有下列分布函数和密度函数：

$$F(x) = P(X \leq x) = \frac{1}{1 + e^{-(x-\mu)/\gamma}}$$
$$f(x) = F'(x) = \frac{e^{-(x-\mu)/\gamma}}{\gamma(1 + e^{-(x-\mu)/\gamma})^2}$$

式中， $\mu$ 为位置参数， $\gamma > 0$ 为形状参数。

### 指数分布族的定义

- Reference: [https://en.wikipedia.org/wiki/Exponential\\_family](https://en.wikipedia.org/wiki/Exponential_family)
- 对于随机变量 $x$ ，在给定参数 $\theta$ 下，其概率分别满足如下形式：

$p(x|\theta) = h(x)\exp(\theta^T T(x) - A(\theta))$  称之为指数分布族

其中： $g(\theta)$ 表示归一化系数， $h(x) > 0$

### 证明

二项逻辑斯蒂回归模型的分布函数为：

$$P(Y = 1|X) = \frac{e^{\beta_0 + \beta^T X}}{1 + e^{\beta_0 + \beta^T X}}$$
$$P(Y = 0|X) = \frac{1}{1 + e^{\beta_0 + \beta^T X}}$$

似然函数为：

$$L(\beta) = \prod_{i=1}^N P(Y = y_i | X = x_i)$$
$$= \prod_{i=1}^N \left( \frac{e^{\beta_0 + \beta^T X}}{1 + e^{\beta_0 + \beta^T X}} \right)^{y_i} \left( \frac{1}{1 + e^{\beta_0 + \beta^T X}} \right)^{1-y_i}$$
$$= \exp\left(\sum_{i=1}^N (y_i(\beta_0 + \beta^T X) - \log(1 + e^{\beta_0 + \beta^T X}))\right)$$

满足指数分布族的形式，其中

- $h(x) = 1$
- $\theta = (\beta_0, \beta)$
- $T(x) = y_i(1, x)$
- $A(\theta) = \log(1 + e^{\beta_0 + \beta^T X})$

多项逻辑斯蒂回归模型：

$$P(Y = k|X) = \frac{e^{\beta_{k0} + \beta_k^T X}}{1 + \sum_{l=1}^{K-1} e^{\beta_{l0} + \beta_l^T X}}$$

证明过程与二项逻辑斯蒂回归模型类似，满足指数分布族的形式

## 6.2 写出逻辑斯蒂回归模型学习的梯度下降算法

定义6.2 (逻辑斯谛回归模型) 二项逻辑斯谛回归模型是如下的条件概率分别:

$$P(Y = 1|x) = \frac{\exp(w \cdot x + b)}{1 + \exp(w \cdot x + b)}$$

$$P(Y = 0|x) = \frac{1}{1 + \exp(w \cdot x + b)}$$

这里,  $x \in R^n$  是输入,  $Y \in \{0, 1\}$  是输出,  $w \in R^n$  和  $b \in R^n$  是参数,  $w$  称为权值向量,  $b$  称为偏置,  $w \cdot x$  为  $w$  和  $x$  的内积

逻辑斯谛回归模型学习的梯度下降法

逻辑斯谛回归模型的对数似然函数为:

$$L(w) = \sum_{i=1}^N [y_i(w \cdot x_i) - \log(1 + \exp(w \cdot x_i))]$$

将对数似然函数求偏导, 可得

$$\frac{\partial L(w)}{\partial w^{(k)}} = \sum_{i=1}^N \left[ x_i \cdot y_i - \frac{\exp(w^{(k)} \cdot x_i) \cdot x_i}{1 + \exp(w^{(k)} \cdot x_i)} \right] \quad (1)$$

梯度函数为

$$\nabla L(w) = \left[ \frac{\partial L(w)}{\partial w^{(0)}}, \dots, \frac{\partial L(w)}{\partial w^{(n)}} \right] \quad (2)$$

根据书中附录A 梯度下降法得逻辑斯谛回归模型学习的梯度下降算法:

- 输入: 目标函数  $f(w)$ , 梯度函数  $g(w) = \nabla f(w)$ , 精度  $\varepsilon$
- 输出:  $f(w)$  的极大值  $w^*$

1. 初值  $w^{(0)} \in R^n$ ,  $k = 0$

2. 计算  $f(w^{(k)}) = \sum_{i=1}^N [y_i(w^{(k)} \cdot x_i) - \log(1 + \exp(w^{(k)} \cdot x_i))]$

3. 计算梯度  $g_k = g(w^{(k)}) = \sum_{i=1}^N \left[ x_i \cdot y_i - \frac{\exp(w^{(k)} \cdot x_i) \cdot x_i}{1 + \exp(w^{(k)} \cdot x_i)} \right] :$

3.1 当  $\|g_k\| < \varepsilon$  时, 停止迭代, 令  $w^* = w^{(k)}$

3.2 否则, 令  $p_k = -g(w^{(k)})$ , 求  $\lambda_k$ , 使  $f(w^{(k)} + \lambda_k p_k) = \max_{\lambda \geq 0} f(w^{(k)} + \lambda p_k)$

4. 置  $w^{(k+1)} = w^{(k)} + \lambda_k p_k$ , 计算  $f(w^{(k+1)})$ :

当  $\|f(w^{(k+1)}) - f(w^{(k)})\| < \varepsilon$  或  $\|w^{(k+1)} - w^{(k)}\| < \varepsilon$  时, 停止迭代, 令  $w^* = w^{(k+1)}$

5.  $k = k + 1$ , 转 step 3