

## 9.1

如例9.1的三硬币模型，假设观测数据不变，试选择不同的初值，例如， $\pi^{(0)} = 0.46, p^{(0)} = 0.55, q^{(0)} = 0.67$ ，求模型参数为 $\theta = (\pi, p, q)$ 的极大似然估计。

**例9.1（三硬币模型）** 假设有3枚硬币，分别记作A，B，C。这些硬币正面出现的概率分别是 $\pi$ ， $p$ 和 $q$ 。进行如下掷硬币试验：先掷硬币A，根据其结果选出硬币B或硬币C，正面选硬币B，反面选硬币C；然后掷选出的硬币，掷硬币的结果，出现正面记作1，出现反面记作0；独立地重复 $n$ 次试验（这里， $n = 10$ ），观测结果如下：

1, 1, 0, 1, 0, 0, 1, 0, 1, 1

假设只能观测到掷硬币的结果，不能观测掷硬币的过程。

三硬币模型可以写作

$$\begin{aligned} P(y|\theta) &= \sum_z P(y, z|\theta) = \sum_z P(z|\theta)P(y|z, \theta) \\ &= \pi p^y(1-p)^{1-y} + (1-\pi)q^y(1-q)^{1-y} \end{aligned}$$

- 根据书中第9章的例9.1的三硬币模型的EM算法：

EM算法首先选取参数的初值，记作 $\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)})$ ，然后通过下面的步骤迭代计算参数的估计值，直至收敛为止

第 $i$ 次迭代参数的估计值为 $\theta^{(i)} = (\pi^{(i)}, p^{(i)}, q^{(i)})$ 。EM算法的第 $i + 1$ 次迭代如下：

**E步：**计算在模型参数 $\pi^{(i)}, p^{(i)}, q^{(i)}$ 下观测数据 $y_j$ 来自掷硬币B的概率：

$$\mu_j^{(i+1)} = \frac{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j}}{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j} + (1-\pi^{(i)})(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j}}$$

**M步：**计算模型参数的新估计值：

$$\begin{aligned} \pi^{(i+1)} &= \frac{1}{n} \sum_{j=1}^N \mu_j^{(i+1)} \\ p^{(i+1)} &= \frac{\sum_{j=1}^n \mu_j^{(i+1)} y_j}{\sum_{j=1}^n \mu_j^{(i+1)}} \\ q^{(i+1)} &= \frac{\sum_{j=1}^n (1 - \mu_j^{(i+1)}) y_j}{\sum_{j=1}^n (1 - \mu_j^{(i+1)})} \end{aligned}$$

采用编程方法直接计算解决

```

2 class coin:
3     def __init__(self,threshold=1e-6,max_iter=1000,theta):
4         #####
5         # 初始化模型参数      #
6         # threshold:收敛阈值  #
7         # max_iter:最大迭代次数 #
8         # theta:模型参数的初值 #
9         #####
10        self.threshold=threshold
11        self.max_iter=max_iter
12        self.pi,self.p,self.q=theta
13    def mu(self,j):
14        #####
15        # (E步) 计算mu          #
16        # j:观测数据y的第j个    #
17        # 返回在模型参数下观测数据yj来自掷硬币B的概率 #
18        #####
19        pro_1=self.pi*math.pow(self.p,data[j])*math.pow((1-self.p),1-data[j])
20        pro_2=(1-self.pi)*math.pow(self.q,data[j])*math.pow((1-self.q),1-data[j])
21        return pro_1/(pro_1+pro_2)
22    def fit(self,data):
23        #####
24        # 模型迭代              #
25        # data:观测数据          #
26        #####
27        count=len(data)
28        print("模型参数的初值: ")
29        print("pi={},p={},q={}".format(self.pi,self.p,self.q))
30        print("EM算法训练过程: ")
31        for i in range(self.max_iter):
32            # (E步) 得到在模型参数下观测数据yj来自掷硬币B的概率
33            _mu=[self.mu(j) for j in range(count)]
34            # (M步) 计算模型参数的新估计值
35            pi=1/count*sum(_mu)
36            p=sum([_mu[k]*data[k] for k in range(count)]/sum([_mu[k] for k in range(count)])
37            q=sum([(1-_mu[k])*data[k] for k in range(count)]/sum([(1-_mu[k]) for k in range(count)]))
38            print('第{}次:pi={:.4f},p={:.4f},q={:.4f}'.format(i+1,pi,p,q))
39            #计算误差值
40            error=abs(self.pi-pi)+abs(self.p-p)+abs(self.q-q)
41            self.pi=pi
42            self.p=p
43            self.q=q
44            #判断是否收敛
45            if error<self.threshold:
46                print("模型参数的极大似然估计: ")
47                print("pi={:.4f},p={:.4f},q={:.4f}".format(self.pi,self.p,self.q))
48                break

```

```

1 # 加载数据
2 data = [1, 1, 0, 1, 0, 0, 1, 0, 1, 1]
3 # 模型参数的初值
4 init_prob = [0.46, 0.55, 0.67]
5
6 # 三硬币模型的EM模型
7 em = ThreeCoinEM(prob=init_prob, tol=1e-5, max_iter=100)
8 # 模型训练
9 em.fit(data)

```

```

1 模型参数的初值:
2 pi=0.46,p=0.55,q=0.67
3 EM算法训练过程:
4 第1次:pi=0.4619,p=0.5346,q=0.6561
5 第2次:pi=0.4619,p=0.5346,q=0.6561
6 模型参数的极大似然估计:
7 pi=0.4619,p=0.5346,q=0.6561

```

## 9.2 证明定理9.2

**定理 9.2** 设  $L(\theta) = \log P(Y|\theta)$  为观测数据的对数似然函数,  $\theta^{(i)} (i = 1, 2, \dots)$  为 EM 算法得到的参数估计序列,  $L(\theta^{(i)}) (i = 1, 2, \dots)$  为对应的对数似然函数序列。

(1) 如果  $P(Y|\theta)$  有上界, 则  $L(\theta^{(i)}) = \log P(Y|\theta^{(i)})$  收敛到某一值  $L^*$ ;

(2) 在函数  $Q(\theta, \theta')$  与  $L(\theta)$  满足一定条件下, 由 EM 算法得到的参数估计序列  $\theta^{(i)}$  的收敛值  $\theta^*$  是  $L(\theta)$  的稳定点。

(1):

- 由定理9.1, 有  $P(y|\theta^i)$  是单调递增的, 所以  $L(\theta^i)$  是单调递增的
- 由于  $P(y|\theta^i)$  是有上界的, 所以  $P(y|\theta^i)$  有上界, 所以  $L(\theta^i)$  有上界
- 由单调有界定理, 有  $L(\theta^i)$  收敛

(2):

参考: Wu CF J On the convergence properties of the EM algorithm. The Annals of Statistics, 1983, 11:95-103

**GLOBAL CONVERGENCE THEOREM.** *Let the sequence  $\{x_k\}_{k=0}^{\infty}$  be generated by  $x_{k+1} \in M(x_k)$ , where  $M$  is a point-to-set map on  $X$ . Let a solution set  $\Gamma \subset X$  be given, and suppose that: (i) all points  $x_k$  are contained in a compact set  $S \subset X$ ; (ii)  $M$  is closed over the complement of  $\Gamma$ ; (iii) there is a continuous function  $\alpha$  on  $X$  such that (a) if  $x \notin \Gamma$ ,  $\alpha(y) > \alpha(x)$  for all  $y \in M(x)$ , and (b) if  $x \in \Gamma$ ,  $\alpha(y) \geq \alpha(x)$  for all  $y \in M(x)$ .*

*Then all the limit points of  $\{x_k\}$  are in the solution set  $\Gamma$  and  $\alpha(x_k)$  converges monotonically to  $\alpha(x)$  for some  $x \in \Gamma$ .*

Global Convergence Theorem: 全局收敛定理

**THEOREM 1.** *Let  $\{\phi_p\}$  be a GEM sequence generated by  $\phi_{p+1} \in M(\phi_p)$ , and suppose that (i)  $M$  is a closed point-to-set map over the complement of  $\mathcal{S}$  (resp.  $\mathcal{M}$ ), (ii)  $L(\phi_{p+1}) > L(\phi_p)$  for all  $\phi_p \notin \mathcal{S}$  (resp.  $\mathcal{M}$ ).*

*Then all the limit points of  $\{\phi_p\}$  are stationary points (local maxima) of  $L$ , and  $L(\phi_p)$  converges monotonically to  $L^* = L(\phi^*)$  for some  $\phi^* \in \mathcal{S}$  (resp.  $\mathcal{M}$ ).*

- 对EM算法， $Q(\theta, \theta^i)$ 对 $\theta$ ， $\theta_i$ 是连续的是closeness of  $M$ 的充分条件,于是有Theorem2

**THEOREM 2.** *Suppose  $Q$  satisfies the continuity condition (10). Then all the limit points of any instance  $\{\phi_p\}$  of an EM algorithm are stationary points of  $L$  and  $L(\phi_p)$  converges monotonically to  $L^* = L(\phi^*)$  for some stationary point  $\phi^*$ .*

- 对EM算法来说，容易说明 $Q(\theta, \theta^i)$ 对 $\theta$ ， $\theta_i$ 是连续,满足Theorem1(i)的条件
- 由定理9.1，有 $P(y|\theta^i)$ 是单调递增的,即 $L(\theta^i)$ 是单调递增的,所以满足Theorem1(ii)的条件
- 则自然满足Theorem 1的条件，同时得证在函数 $Q(\theta, \theta')$ 与 $L(\theta)$ 满足一定条件下，由EM算法得到的参数估计序列 $\theta^i$ 的收敛值 $\theta^*$ 是 $L(\theta)$ 的稳定点。

**PROOF.** Since (10) is sufficient for (i) of Theorem 1, it remains to prove (ii) of Theorem 1 for all  $\phi_p \notin \mathcal{S}$ . Consider a  $\phi_p$ , which is in the interior of  $\Omega$  by (9). Since  $\phi_p$  maximizes  $H(\phi | \phi_p)$  over  $\phi \in \Omega$  according to (4),  $D^{10}H(\phi_p | \phi_p) = 0$ . Therefore  $DL(\phi_p) = D^{10}Q(\phi_p | \phi_p) \neq 0$  for any  $\phi_p \notin \mathcal{S}$  from the definition of  $\mathcal{S}$ , implying that  $\phi_p$  is not a local maximum of  $Q(\phi | \phi_p)$  over  $\phi \in \Omega$ . From the definition of the M-step,  $Q(\phi_{p+1} | \phi_p) > Q(\phi_p | \phi_p)$ . Together with (4), this proves  $L(\phi_{p+1}) > L(\phi_p)$  for all  $\phi_p \notin \mathcal{S}$ . The desired result follows.  $\square$