

习题15.2

试求矩阵

$$A = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

的奇异值分解并写出其外积展开式。

矩阵 A 的外积展开式：

a.计算矩阵 A 的奇异值分解

$$A^T A = \begin{bmatrix} 5 & 11 \\ 11 & 25 \end{bmatrix}$$

$$(A^T A - \lambda I)x = 0$$

$$\lambda^2 - 30\lambda + 4 = 0$$

$$\lambda_1 = 15 - \sqrt{221} \quad \lambda_2 = \sqrt{221} + 15$$

- 将 λ_1 代入 $(A^T A - \lambda I)x = 0$ ，得到 v_1
- 将 λ_2 代入 $(A^T A - \lambda I)x = 0$ ，得到 v_2
- 归一化 v_1, v_2 得到 V ..
- 发现计算较为复杂，直接使用numpy库计算,算数求解过程如书中所述。

给定 $m \times n$ 矩阵 A ，可以写出矩阵奇异值分解的计算过程。

(1) 求 $A^T A$ 的特征值和特征向量。

计算对称矩阵 $W = A^T A$ 。

求解特征方程

$$(W - \lambda I)x = 0$$

得到特征值 λ_i ，并将特征值由大到小排列

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$$

将特征值 λ_i ($i = 1, 2, \cdots, n$)代入特征方程求得对应的特征向量。

(2) 求 n 阶正交矩阵 V

将特征向量单位化，得到单位特征向量 v_1, v_2, \cdots, v_n ，构成 n 阶正交矩阵 V

$$V = [v_1 \ v_2 \ \cdots \ v_n]$$

(3) 求 $m \times n$ 对角矩阵 Σ

计算 A 的奇异值

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \cdots, n$$

构造 $m \times n$ 矩形对角矩阵 Σ ，主对角线元素是奇异值，其余元素是零

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \cdots, \sigma_n)$$

(4) 求 m 阶正交矩阵 U

对 A 的前 r 个正奇异值，令

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \cdots, r$$

得到

$$U_1 = [u_1 \ u_2 \ \cdots \ u_r]$$

求 A^T 的零空间的一组标准正交基 $u_{r+1}, u_{r+2}, \cdots, u_m$ ，令

$$U_2 = [u_{r+1} \ u_{r+2} \ \cdots \ u_m]$$

并令

$$U = [U_1 \ U_2]$$

(5) 得到奇异值分解

$$A = U \Sigma V^T$$

```
import numpy as np
A = np.array([[2, 4],
              [1, 3],
              [0, 0],
              [0, 0]])
U, S, V = np.linalg.svd(A)
np.set_printoptions()
print("U=", U)
print("S=", S)
print("V=", V.T)
```

```
U= [[-0.81741556 -0.57604844  0.          0.          ]
     [-0.57604844  0.81741556  0.          0.          ]
     [ 0.          0.          1.          0.          ]
     [ 0.          0.          0.          1.          ]]
S= [5.4649857  0.36596619]
V= [[-0.40455358 -0.9145143 ]
     [-0.9145143  0.40455358]]
```

b.根据奇异值分解的结果，求得外积展开式

矩阵A的外积展开式为

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T$$

其中

$$\sigma_1 = 5.4649857, \sigma_2 = 0.36596619$$

$$u_1 = \begin{bmatrix} -0.81741556 \\ -0.57604844 \\ 0 \\ 0 \end{bmatrix}$$

$$u_2 = \begin{bmatrix} -0.57604844 \\ 0.81741556 \\ 0 \\ 0 \end{bmatrix}$$

$$v_1^T = [-0.40455358, -0.9145143]$$

$$v_2^T = [-0.9145143, 0.40455358]$$

```
approx = S[0] * np.outer(U[:, 0], V[:, 0]) + S[1] * np.outer(U[:, 1], V[:, 1])
print("A=", approx)
```

```
A= [[ 2.  4.]
     [ 1.  3.]
     [-0.  0.]
     [-0.  0.]
```

习题15.4

证明任何一个秩为1的矩阵可以写成两个向量的外积形式，并给出实例。

a.假设矩阵 A 的秩为1，求其奇异值分解

存在矩阵 A 的奇异值分解

$$A = U \Sigma V^T \tag{1}$$

根据矩阵 A 的秩与对角矩阵 Σ 的秩之间的关系：

$$\text{rank}(\Sigma) = \text{rank}(A) = 1$$

∴ 对角矩阵 Σ 的奇异值是降序排列的，所以其中的非零元素一定位于第一行第一列，其余元素均为零。所以，对角矩阵 Σ 可以写成如下形式：

$$\begin{bmatrix} \sigma_1 & & \\ & O_{(m-1) \times (n-1)} & \\ & & \end{bmatrix}_{m \times n}$$

设 $a = [1, 0, \dots, 0]_{m \times 1}^T, b = [\sigma_1, 0, \dots, 0]_{n \times 1}^T$ ，可得： $\Sigma = ab^T$

代入式 (1) 中可得：

$$A = Uab^TV^T = (Ua)(Vb)^T$$

其中， Ua 是 $m \times 1$ 阶的列向量， Vb 是 $n \times 1$ 阶的列向量,即矩阵 A 可以写成向量 Ua 和向量 Vb 的外积形式，得证

b.实例

书15.5的矩阵 $A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \\ 0 & 0 \end{bmatrix}$ 的秩为1，矩阵 A 的奇异值分解为

$$\begin{aligned} A &= U \Sigma V^T \\ &= \begin{bmatrix} \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} & 0 \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{10} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ 0 & 0 \end{bmatrix} \end{aligned}$$

得到：

$$\begin{aligned} \Sigma &= \begin{bmatrix} \sqrt{10} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} [\sqrt{10}, 0] = ab^T \\ Ua &= \begin{bmatrix} \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \\ 0 \end{bmatrix}, Vb = \begin{bmatrix} \sqrt{5} \\ \sqrt{5} \end{bmatrix} \end{aligned}$$

$$\therefore (Ua)(Vb)^T = \begin{bmatrix} 1 & 1 \\ 2 & 2 \\ 0 & 0 \end{bmatrix} = A$$

习题15.5

搜索中的点击数据记录用户搜索时提交的查询语句，点击的网页URL以及点击的次数构成一个二部图，其中一个结点集合 $\{q_i\}$ 表示查询，另一个结点集合 $\{u_j\}$ 表示URL，边表示点击关系，边上的权重表示点击次数。图15.2是一个简化的点击数据例。点击数据可以由矩阵表示，试对该矩阵进行奇异值分解，并解释得到的三个矩阵所表示的内容。

$$A = \begin{bmatrix} 0 & 20 & 5 & 0 & 0 \\ 10 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

a.奇异值分解;

```
import numpy as np
A = np.array([[0, 20, 5, 0, 0],
              [10, 0, 0, 3, 0],
              [0, 0, 0, 0, 1],
              [0, 0, 1, 0, 0]])
U, S, V = np.linalg.svd(A)
print("U=", U)
print("S=", S)
print("V=", V.T)

U= [[ 9.99930496e-01 -1.01352447e-16  0.00000000e+00 -1.17899939e-02]
     [ 0.00000000e+00  1.00000000e+00  0.00000000e+00 -8.65973959e-15]
     [ 0.00000000e+00  0.00000000e+00  1.00000000e+00  0.00000000e+00]
     [ 1.17899939e-02  8.65973959e-15  0.00000000e+00  9.99930496e-01]]
S= [20.61695792 10.44030651  1.          0.97007522]
V= [[ 0.00000000e+00  9.57826285e-01 -0.00000000e+00 -7.97105437e-16
      2.87347886e-01]
     [ 9.70007796e-01 -2.31404926e-16 -0.00000000e+00 -2.43073808e-01
     -1.01402229e-16]
     [ 2.43073808e-01  8.02571613e-16  0.00000000e+00  9.70007796e-01
      2.10571835e-16]
     [ 0.00000000e+00  2.87347886e-01  0.00000000e+00  0.00000000e+00
     -9.57826285e-01]
     [ 0.00000000e+00  0.00000000e+00  1.00000000e+00  0.00000000e+00
      0.00000000e+00]]
```

b.解释 U 、 Σ 、 V 代表的内容

- 1. 矩阵 U ：
 - 矩阵 U 的列向量是点击矩阵 A 的左奇异向量。
 - 每个左奇异向量表示一个查询在低维特征空间中的表示。
 - 例如，矩阵 U 的第一列向量与查询 q_1 的关系密切。
- 2. 矩阵 Σ ：
 - Σ 是一个对角矩阵，其对角元素是奇异值，表示点击矩阵 A 的能量或重要性。
 - 较大的奇异值表示更多的信息或较高的重要性，较小的奇异值表示较少的信息或较低的重要性。
 - 例如，奇异值 σ_1 和 σ_2 较大，表示前两个特征捕捉了矩阵 A 中的大部分信息。
- 3. 矩阵 V^T ：
 - 矩阵 V^T 的行向量是点击矩阵 A 的右奇异向量。
 - 每个右奇异向量表示一个 URL 在低维特征空间中的表示。
 - 例如，矩阵 V^T 的第一列表示网页 u_2 与特征 1 的相似度最高，因此在查询 q_1 时点击网页 u_2 的次数最多。

习题16.1

对以下样本数据进行主成分分析：

$$X = \begin{bmatrix} 2 & 3 & 3 & 4 & 5 & 7 \\ 2 & 4 & 5 & 5 & 6 & 8 \end{bmatrix}$$

编程解决

```
import numpy as np

def pca_svd(samples, num_components):
    #####
    # Perform Principal Component Analysis (PCA) using Singular Value Decomposition (SVD).
    # :param samples: The sample matrix (each column represents a sample).
    # :param num_components: The number of principal components to retain.
    # :return: The feature vector matrix V, the sample principal component matrix Y.
    #####
    num_samples = samples.shape[1]
    # Construct a new matrix T by normalizing the samples matrix
    T = samples.T / np.sqrt(num_samples - 1)
    # Perform truncated SVD on the matrix T
    U, S, V = np.linalg.svd(T)
    V = V[:, :num_components]
    # Compute the kxn sample principal component matrix
    return V, np.dot(V.T, samples)

# Sample data
X = np.array([[2, 3, 3, 4, 5, 7],
              [2, 4, 5, 5, 6, 8]])
X = X.astype("float64")
# Normalize variables
mean = np.mean(X, axis=1)
variance = np.var(X, axis=1)
for i in range(X.shape[0]):
    X[i] = (X[i, :] - mean[i]) / np.sqrt(variance[i])
# Set precision to 3 decimal places
np.set_printoptions(precision=3, suppress=True)
V, principal_components = pca_svd(X, 2)
print("Orthogonal matrix V:")
print(V)
print("Sample principal component matrix Y:")
print(principal_components)

Orthogonal matrix V:
[[ 0.707  0.707]
 [ 0.707 -0.707]]
Sample principal component matrix Y:
[[-2.028 -0.82  -0.433  0.      0.82  2.461]
 [ 0.296 -0.046 -0.433  0.      0.046  0.137]]
```

习题16.2

证明样本协方差矩阵 S 是总体协方差矩阵 Σ 的无偏估计。

无偏估计的定义

如果参数 θ 的某个估计 $\hat{\theta}$ 满足 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 是无偏的。

$$\hat{\Sigma} = \frac{1}{n} A^d = \frac{1}{n} \sum_{\alpha=1}^{n-1} z_{\alpha} z'_{\alpha}$$

z_1, \dots, z_{n-1} 独立同分布于 $N_p(0, \Sigma)$ ，于是

$$E(\hat{\Sigma}) = \frac{1}{n} \sum_{\alpha=1}^{n-1} z_{\alpha} z'_{\alpha} = \frac{n-1}{n} \Sigma$$

$\hat{\Sigma}$ 不是 Σ 的无偏估计，但可修正一下使之成为无偏估计。令

$$S = \frac{1}{n-1} A$$

则 S 是 Σ 的无偏估计。在实用中普遍采用 S 来估计 Σ 。

样本协方差矩阵 S ：

$$S = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'$$

令：

$$A = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'$$

即证明样本协方差矩阵 S 的期望等于总体协方差矩阵 Σ ：

$$E(S) = E\left(\frac{1}{n-1}A\right) = \frac{1}{n-1}E(A) = \Sigma$$

即证：

$$\begin{aligned} E(A) &= (n-1)\Sigma \\ E(A) &= E\left[\sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'\right] \\ &= nE(\hat{\Sigma}) \\ &= n \cdot \frac{n-1}{n}\Sigma \\ &= (n-1)\Sigma \end{aligned}$$

- 由此可知，样本协方差矩阵 S 是总体协方差矩阵 Σ 的无偏估计。

习题16.3

设 X 为数据规范化样本矩阵，则主成分等价于求解以下最优化问题：

$$\begin{aligned} \min_L \quad & \|X - L\|_F \\ \text{s.t.} \quad & \text{rank}(L) \leq k \end{aligned}$$

其中， F 是弗罗贝尼乌斯范数， k 是主成分个数。试问为什么？

定义15.4（弗罗贝尼乌斯范数） 设矩阵 $A \in R^{m \times m}$ ， $A = [a_{ij}]_{m \times m}$ ，定义矩阵 A 的弗罗贝尼乌斯范数为

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n (a_{ij})^2\right)^{\frac{1}{2}}$$

优化问题的目标函数进行如下变换：

$$\begin{aligned} \min_L \quad & \left\| \frac{1}{\sqrt{n-1}}X^T - \frac{1}{\sqrt{n-1}}L^T \right\|_F \\ \text{s.t.} \quad & \text{rank}(L) \leq k \end{aligned}$$

令

$$X' = \frac{1}{\sqrt{n-1}}X^T, L' = \frac{1}{\sqrt{n-1}}L^T$$

原最优化问题等价于

$$\begin{aligned} \min_L \quad & \|X' - L'\|_F \\ \text{s.t.} \quad & \text{rank}(L) \leq k \\ & X' = \frac{1}{\sqrt{n-1}}X^T \\ & L' = \frac{1}{\sqrt{n-1}}L^T \end{aligned}$$

对 X' 进行奇异值分解， X' 的主成分个数也为 k 个，则

$$X' = U'\Sigma'V'^T$$

可找到 $\Sigma' = \text{diag}(\lambda'_1, \lambda'_2, \dots, \lambda'_k, 0, 0, \dots, 0)$ 使得变换后的目标函数取最小值，即存在矩阵满足主成分条件。